

中文文字探勘與機器學習

國立臺灣大學共同教育中心

蔡芸琤

文字探勘目標

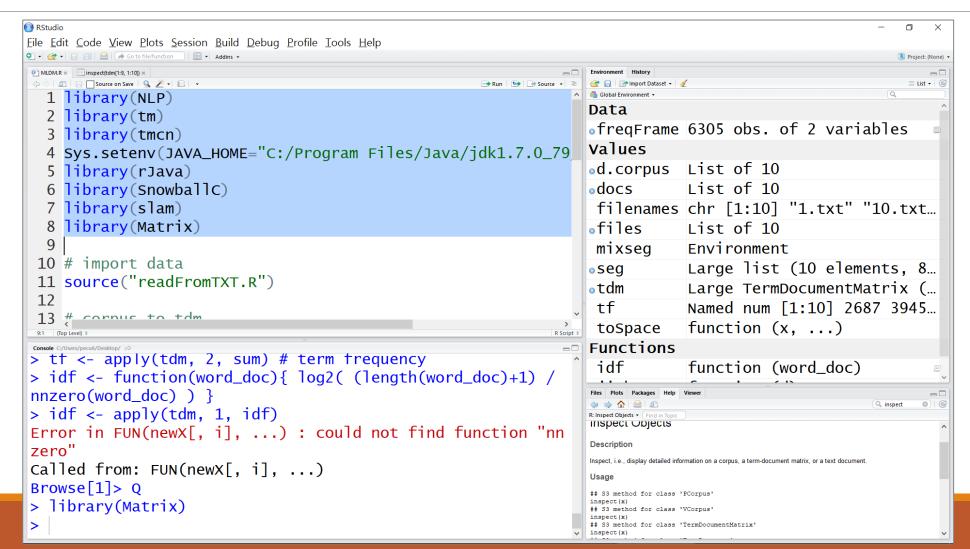
https://buzzorange.com/techorange/2017/04/13/data-to-pxmart-hsu/

- 1. 文字雲 done
- 2. 詞語詞間的關係
- 3. 文本關聯

套件安裝

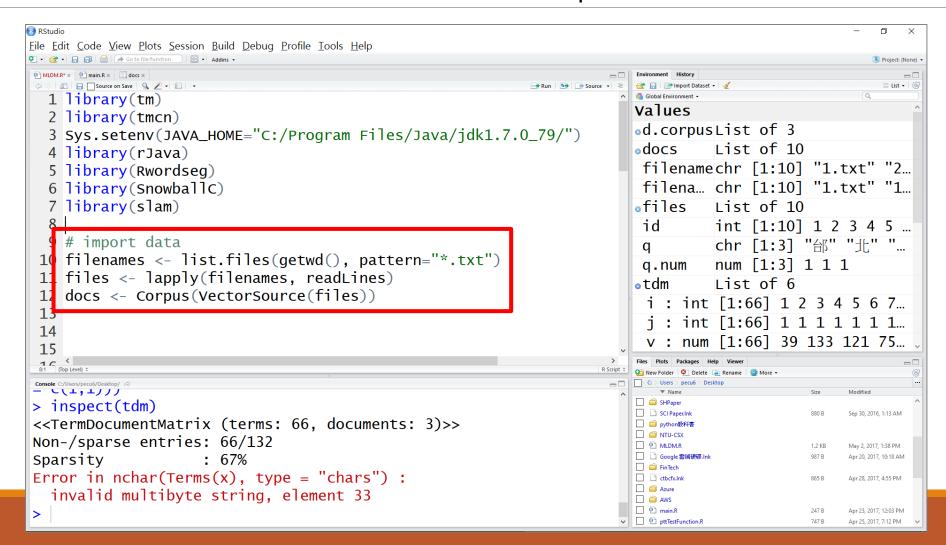
- 1. library(tmcn): https://r-forge.r-project.org/R/?group_id=1571, tm的中文包
- 2. librart(tm): 主要的 text mining 套件
- 3. library(rJava): 給 Rwordseg 連到 java 的套件, http://www.oracle.com/technetwork/java/javase/downloads/index-jsp-138363.html, Sys.setenv(JAVA_HOME="C:/Program Files/Java/jdk1.7.0 79/")
- 4. SnowballC、slam、Matrix:輔助套件

套件安裝



資料測試

延續上週抓到的文本,轉成 Corpus 資料格式繼續進行接下來的分析技巧



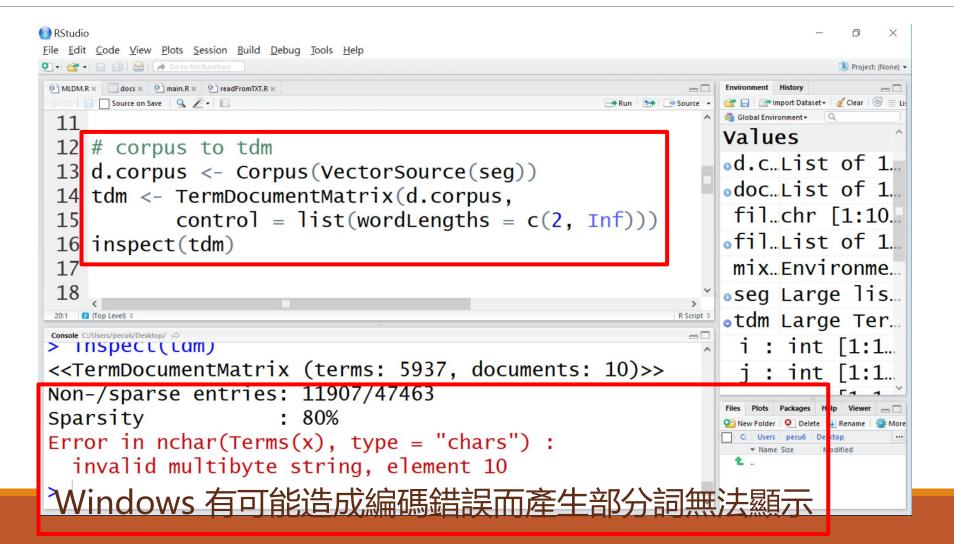
Documents

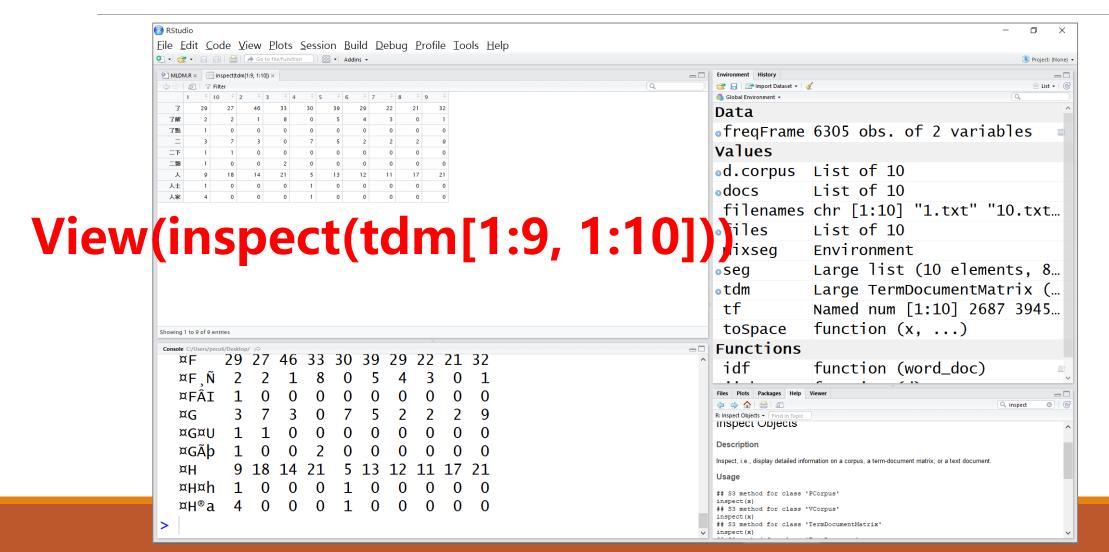
We study the complexity of influencing elections through bribery: How computationally complex is it for an external actor to determine whether by a certain amount of bribing voters a specified candidate can be made the election's winner? We study this problem for election systems as varied as scoring ...

Vector-space representation

	D1	D2	D3	D4	D5
complexity	2		3	2	3
algorithm	3			4	4
entropy	1			2	
traffic		2	3		
network		1	4		

Term-document matrix





	1	2	3	4	5	6	7	8	9	10
了	29	27	46	33	30	39	29	22	21	32
了解	2	2	1	8	0	5	4	3	0	1
了點	1	0	0	0	0	0	0	0	0	0
<u> </u>	3	7	3	0	7	5	2	2	2	9
二下	1	1	0	0	0	0	0	0	0	0
二類	1	0	0	2	0	0	0	0	0	0
人	9	18	14	21	5	13	12	11	17	21
人士	1	0	0	0	1	0	0	0	0	0
人家	4	0	0	0	1	0	0	0	0	0

在文章中出現的次數

- 1. 可以用 slam::row_sums 來算出每個字的總出現次數
- 2. tm::findFreqTerms 直接找最常出現的字
- 3. 兩兩之間可以算相關係數 or 歐幾里德距離

	1	2	3	4	5	6	7	8	9	10
了	29	27	46	33	30	39	29	22	21	32
了解	2	2	1	8	0	5	4	3	0	1
了點	1	0	0	0	0	0	0	0	0	0
	3	7	3	0	7	5	2	2	2	9
二下	1	1	0	0	0	0	0	0	0	0
二類	1	0	0	2	0	0	0	0	0	0
人	9	18	14	21	5	13	12	11	17	21
人士	1	0	0	0	1	0	0	0	0	0
人家	4	0	0	0	1	0	0	0	0	0



TF-IDF (Term Frequency - Inverse Document Frequency)

$$w_{x,y} = tf_{x,y} \times log(\frac{N}{df_x})$$

TF-IDF

Term x within document y

 $tf_{x,y}$ = frequency of x in y

 df_x = number of documents containing x

N = total number of documents

- 1. TF-IDF:是一種用於資訊檢索與文字探勘的常用加權技術, 為一種統計方法,用來評估單詞對於文件的集合或詞庫中一份 文件的重要程度。
- 2. TF (Term Frequency):
 - y 是「某一特定文件」
 - x 是該文件中所使用單詞或單字的「其中一種」
 - n(x,y) 就是 x 在 y 當中的「出現次數」
 - tf(x,y) = n(x,y) / (n(1,y)+n(2,y)+n(3,y)+...+n(i,j))

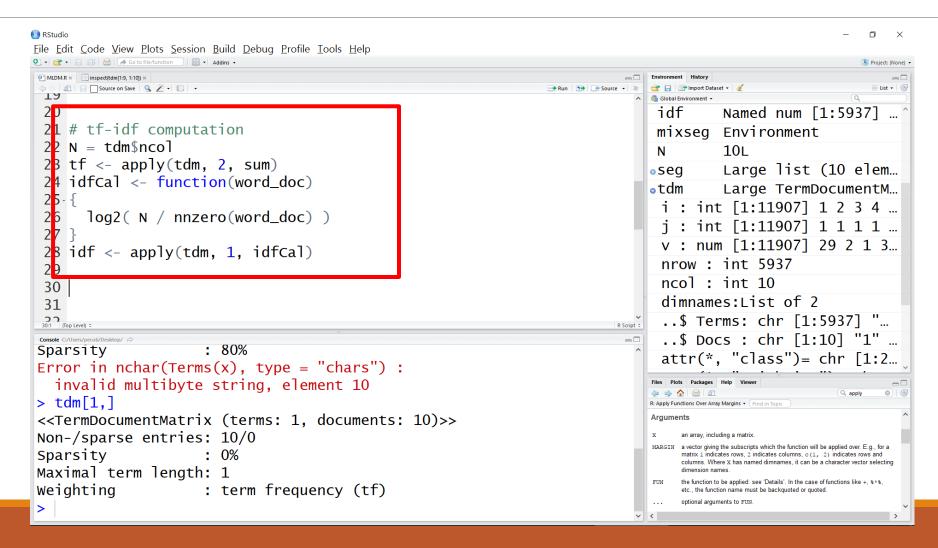
TF (Term Frequency)

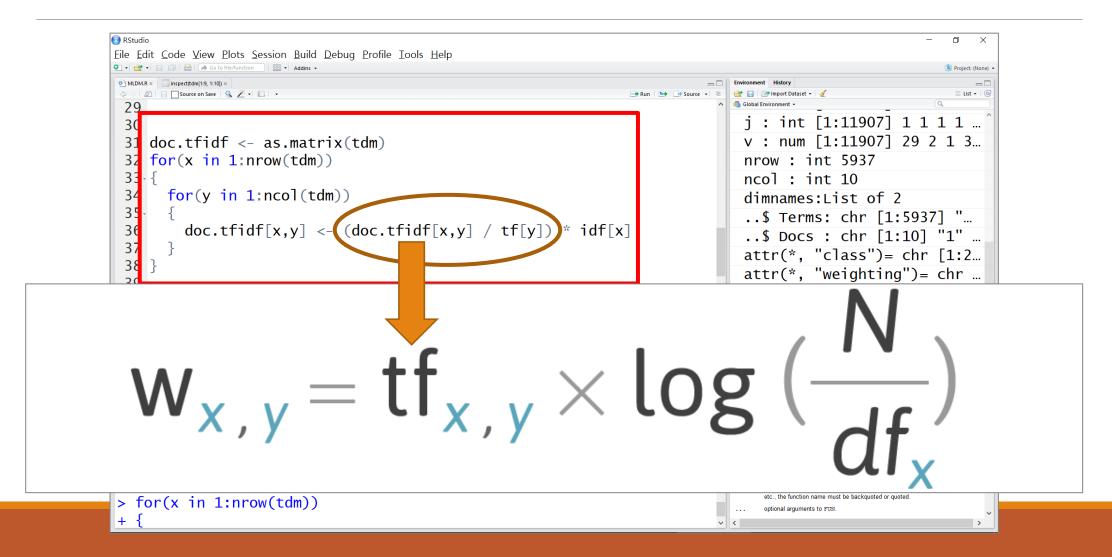
- 1. 例如第一篇文件篩選出「健康」、「富有」
 - 「健康」在該篇文件中出現 70 次,「富有」出現 30 次,
 - 「健康」的 tf = 70 / (70+30) = 70/100 = 0.7 ,
 - 「富有」的 tf = 30 / (70+30) = 30/100 = 0.3;
- 2. 第二篇文件同樣篩選出「健康」、「富有」
 - 「健康」在該篇文件中出現 40 次,「富有」出現 60 次,
 - 「健康」的 tf = 40 / (40+60) = 40/100 = 0.4,
 - · 「富有」的 tf = 60 / (40+60) = 60/100 = 0.6,
- 3. TF 值愈高, 其單詞愈重要。「健康」對第一篇文件比較重要, 「富有」 對第二篇文件比較重要。若搜尋「健康」, 那第一篇文件會在較前面的 位置; 而搜尋「富有」, 則第二篇文章會出現在較前面的位置。

IDF (Inverse Document Frequency)

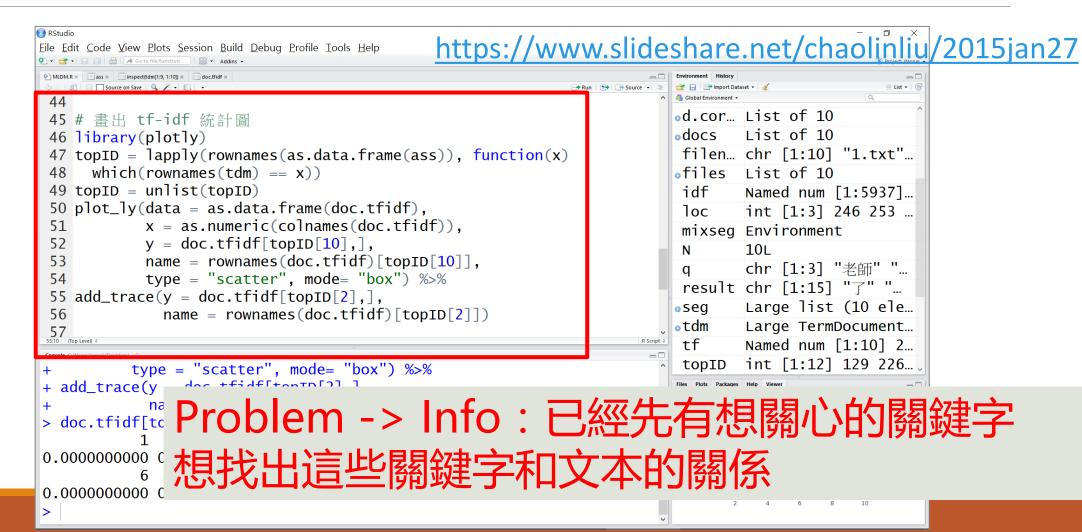
- 1. N 是「所有的文件總數」, x 是文件中所使用的單詞, df(x) 是該單詞在所有文件總數中出現的「文件數」。
 - idf(x) = log (N/df(x)) = log N log df(x).
- 2. 例如有100份文件,「健康」出現在10個文件當中,而「富有」出現在100個文件當中。
 - idf(健康)=log(100/10)=log 100 log 10= 2 1 = 1。
 - idf(富有)=log(100/100)=log 100 log 100 = 2 2 = 0。
- 3. 「健康」出現的機會小,與出現機會很大的「富有」比較起來,便顯得非常重要,因此要加重權重。

將 tf(x,y) * idf(x)(例如:x = 「健康」一詞)來進行計算,以某一特定文件內的高單詞頻率,乘上該單詞在文件總數中的低文件頻率,便可以產生 TF-IDF 權重值,且 TF-IDF 傾向於過濾掉常見的單詞,保留重要的單詞,如此一來,「富有」便不重要了。

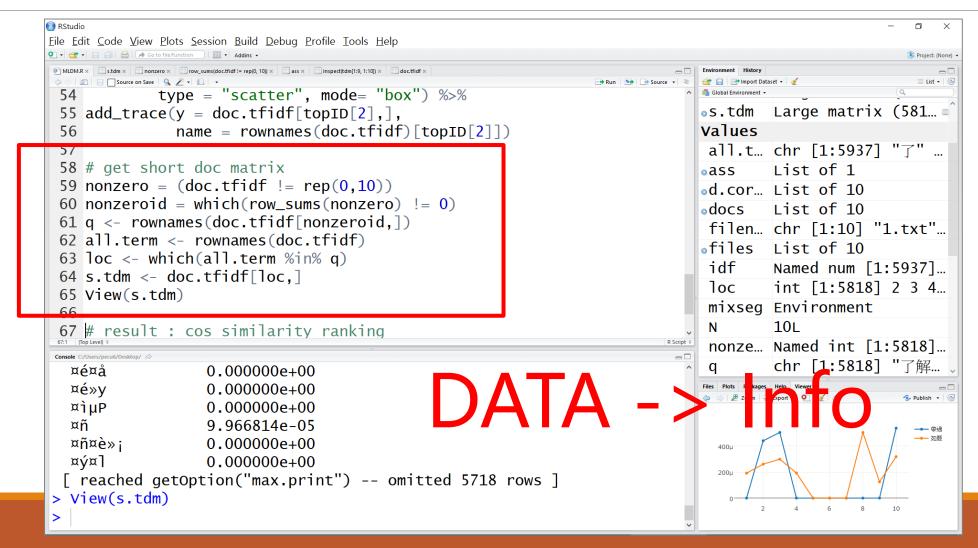




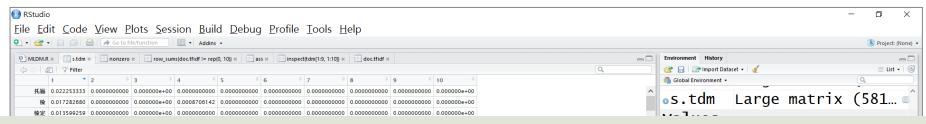
畫出 tf-idf 統計圖



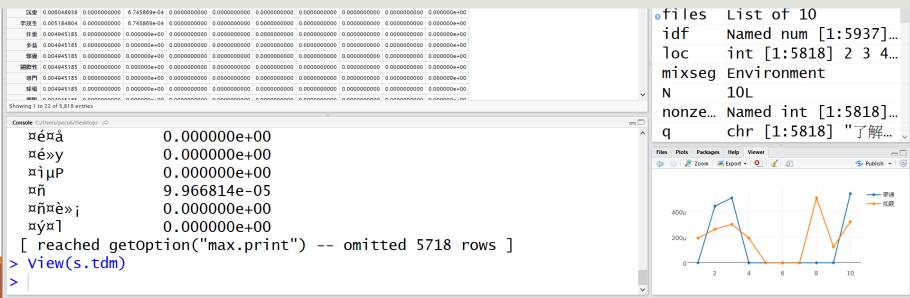
尋找關鍵字與文章之間的關聯



尋找關鍵字與文章之間的關聯



DATA -> Info:從資料中去發掘甚麼才是重要的關鍵字 找出托福、檢定是對第一份文本最重要的關鍵字



餘弦相似性 (cos similarity ranking)

1. 餘弦相似性用在找出相似的文章。

- 句子A:我喜歡看電視,不喜歡看電影。
- 句子B:我不喜歡看電視,也不喜歡看電影。

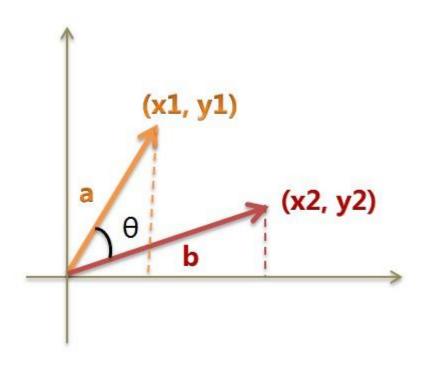
2. 請問怎樣才能計算上面兩句話的相似程度?

基本思路是:如果這兩句話的用詞越相似,它們的內容就應該越相似。 因此,可以從詞頻入手,計算它們的相似程度。

餘弦相似性 (cos similarity ranking)

把文章對應到的 IF-IDF 想像成空間中的向量。兩條線段之間形成一個夾角,如果夾角為0度,意味著方向相同、線段重合;如果夾角為90度,意味著形成直角,方向完全不相似;如果夾角為180度,意味著方向正好相反。因此,我們可以通過夾角的大小,來判斷向量的相似程度。夾角越小,就代表越相似。

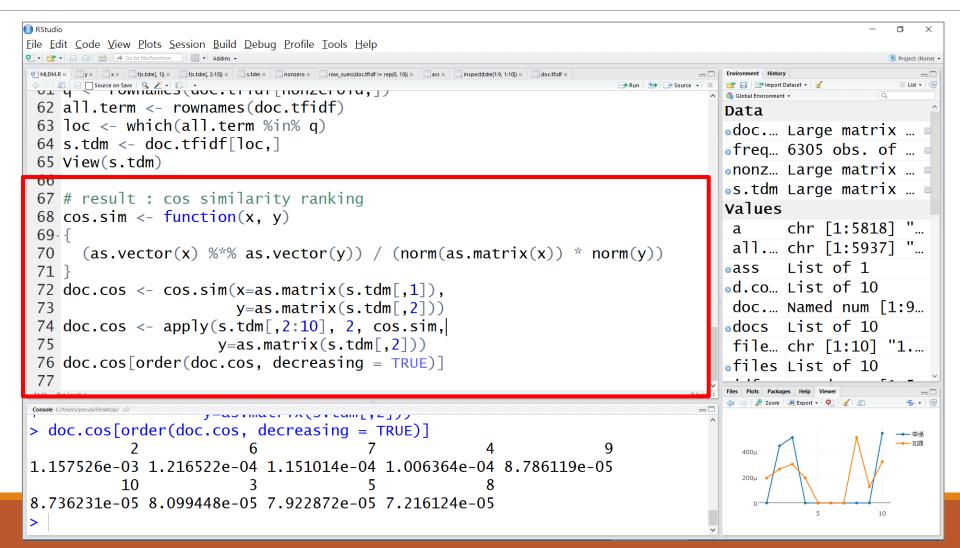
餘弦相似性 (cos similarity ranking)

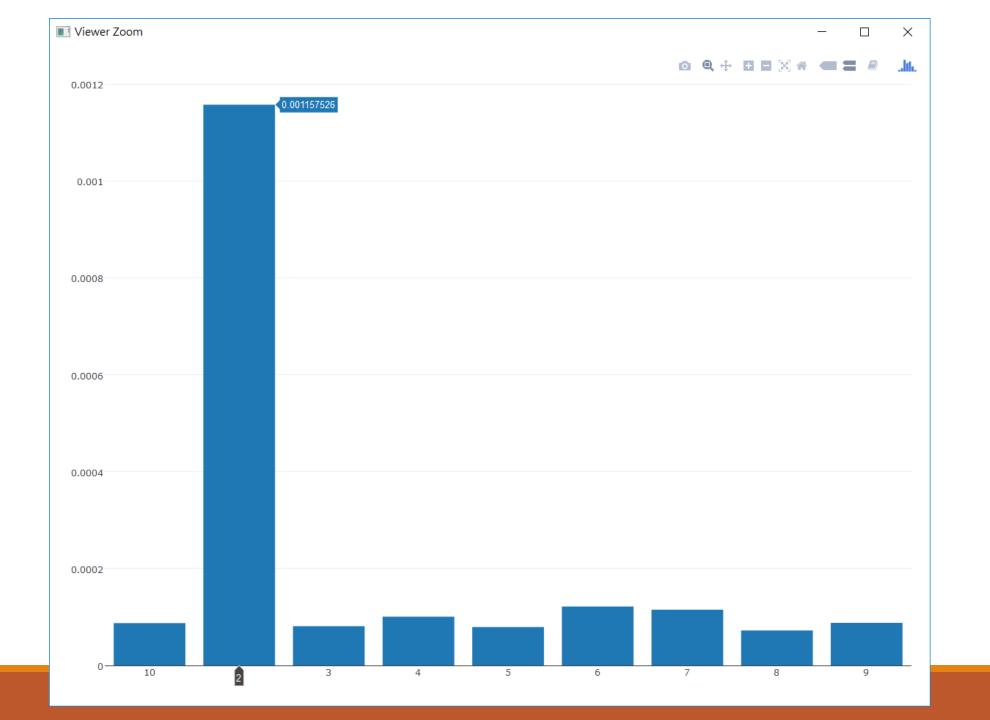


$$\cos\theta = \frac{x_1 x_2 + y_1 y_2}{\sqrt{x_1^2 + y_1^2} \times \sqrt{x_2^2 + y_2^2}}$$

$$\cos\theta = \frac{\sum_{i=1}^{n} (A_i \times B_i)}{\sqrt{\sum_{i=1}^{n} (A_i)^2} \times \sqrt{\sum_{i=1}^{n} (B_i)^2}}$$
$$= \frac{A \cdot B}{|A| \times |B|}$$

哪個文本和第一個文本最相似?





```
RStudio
Eile Edit Code View Plots Session Build Debug Profile Tools Help
♥ ▼ 😭 ▼ 🔒 🚔 🍎 Go to file/function 🗎 🔻 Addins ▼
                                                                                                               Project: (None)
@ | MLDM.R × | a × | orderDoc × | y × | x × | t(s.tdm[, 1]) × | t(s.tdm[, 2:10]) × | s.tdm × | nonzero ×
 Run 🕩 🕩 Source 🕶
 63 loc <- which(all.term %in% q)
                                                                                          Data
 64 s.tdm <- doc.tfidf[loc.]
                                                                                                 9 obs. of 1 v...
 65 View(s.tdm)
                                                                                          odoc.... Large matrix ...
 66
                                                                                          ofreq... 6305 obs. of ...
 67 # result : cos similarity ranking
 68 cos.sim <- function(x, y)
                                                                                          ononz... Large matrix ...
 69-{
                                                                                          os.tdm Large matrix ...
       (as.vector(x) %*% as.vector(y)) / (norm(as.matrix(x)) * norm(y))
                                                                                          Values
 71 }
                                                                                           all.... chr [1:5937] "...
 72 doc.cos <- cos.sim(x=as.matrix(s.tdm[,1]),
                                                                                          oass List of 1
 73
                          y=as.matrix(s.tdm[,2]))
                                                                                          od.co...list of 10
 74 doc.cos \leftarrow apply(s.tdm[,2:10], 2, cos.sim,
                                                                                          doc... Named num [1:9...
                       v=as.matrix(s.tdm[.2]))
                                                                                          odocs List of 10
 76 orderDoc <- doc.cos[order(doc.cos, decreasing = TRUE)]
                                                                                          file... chr [1:10] "1....
 77 plot_ly(data = as.data.frame(orderDoc),
                                                                                          ofiles list of 10
 78
              x = rownames(as.data.frame(orderDoc)),
 79
              v = orderDoc.
                                                                                          듣 🧼 🔑 Zoom 😕 Export 🕶 🧿 🥑 🗊
              name = rownames(doc.tfidf)[topID[10]],
 80
              type = "bar", mode= "box")
                                                                                            0.001
 82
                                                                                           0.0005
> rownames(as.data.frame(orderDoc))
     "2" "6" "7" "4" "9" "10" "3" "5" "8"
```

文字探勘應用面

設計基礎:

文字與文章 -> 數值矩陣

TermDocumentMatrix、TF-IDF、詞頻、word2vec

推廣應用:

以文找文、關聯詞分析、關鍵詞分析、

文件分類、文件分群

相關演算法

- 1. https://docs.microsoft.com/zh-tw/azure/machine-learning/machine-learning-learnin
- 3. https://www.inside.com.tw/2016/07/22/what-is-data-mining

以 TF-IDF 進行 K-Means 分群

https://chtseng.wordpress.com/2017/03/03/%E9%9D%9E%E7%9B%A3%E7%9D%A3%E5%BC%8 F%E5%AD%B8%E7%BF%92-k-means/

以 TF-IDF 進行 K-Means 分群

Kmeans 分群

library(stats)

kmeansOut <- kmeans(doc.tfidf, 10, nstart = 20)

練習問自己問題

https://www.slideshare.net/tw_dsconf/dsc-2016-r-67850142

- 1. 計算人與人之間的距離
- 2. 計算商品與商品之間的距離
- 3. 計算每個人購買種商品的機率
- 4. 計算每個人購買各種商品的最佳順序
- 5. 只要有資料的受眾就可以納入計算
- 6. 從資料出發,不受既定印象與偏見影響,因此可以發掘潛在客戶
- 7. 成功要素:資料量、使用者涵蓋範圍、反應時間